

POLITECHNIKA LUBELSKA
SYSTEMY SZTUCZNEJ INTELIGENCJI

System predykcji wyników wyścigów
Formuły 1 z rozmytym systemem
ekspertskim wspomagającym decyzje
strategiczne o pit-stopach

Autor:

Hubert Kiszka

Prowadzący:

dr inż. Tomasz Nowicki

Lublin, 19 maja 2026

1 Wstęp i opis problemu

Projekt podejmuje temat modelowania i wspomagania decyzji w wyścigach Formuły 1. Głównym celem systemu jest rozwiązanie dwóch powiązanych ze sobą problemów decyzyjnych:

1. **Predykcja wyniku wyścigu:** Prognozowanie, do której z trzech kategorii końcowych (*Podium*, *Punkty*, *Poza punktami*) trafi dany kierowca, bazując na danych historycznych zawodnika na danym torze, pozycji startowej oraz bieżącej formie zespołu i zawodnika.
2. **Strategia zjazdów do boksu:** Opracowanie systemu eksperckiego z przetwarzeniem rozmytym, określającego pilność wykonania pit-stopu na podstawie stopnia zużycia opon, etapu wyścigu, dystansu do rywala oraz prognozy szans na bycie w punktach lub na podium dostarczonej przez system ekspercki.

Do realizacji projektu wykorzystano relacyjny zbiór danych *Formula 1 World Championship (1950-2024)* dostępny na platformie Kaggle.

2 Przetwarzanie danych i inżynieria cech

Surowe dane składają się z wielu powiązanych tabel. W celu przygotowania zbioru treningowego dokonano operacji złączenia kluczowych tabel: `results`, `races`, `drivers`, `constructors`, `qualifying`, `driver_standings` oraz `constructor_standings`.

2.1 Czyszczenie danych i transformacja


Wartości brakujące, reprezentowane jako `\N`, zostały zastąpione wartościami `NaN`. Problem przewidywania pozycji końcowej przekształcono z regresji w zadanie klasyfikacji wieloklasowej poprzez zdefiniowanie zmiennej celu `target`:

$$\text{target} = \begin{cases} \text{Podium} & \text{gdy } \text{positionOrder} \leq 3 \\ \text{Punkty} & \text{gdy } 4 \leq \text{positionOrder} \leq 10 \\ \text{Poza punktami} & \text{gdy } \text{positionOrder} > 10 \end{cases} \quad (1)$$

2.2 Inżynieria cech

Wskaźniki formy zawodników i zespołów obliczono dynamicznie z wykorzystaniem średniej skumulowanej oraz przesunięcia aby obliczać zawsze wyniki tylko do poprzedniego wyniku (Jeżeli model ma określić wynik kierowcy w wyścigu w rundzie 4, to powinien tylko znać wyniki z rund 1,2 oraz 3) . Kluczowe cechy wejściowe modelu (**FEATURES**) obejmują:

- `grid`, `grid_quali` – pozycje startowa oraz kwalifikacyjna,
- `avg_grid_season`, `avg_position_season` – dotychczasowa średnia pozycja startowa i końcowa w bieżącym sezonie,
- `avg_constructor_season` – średnia pozycja końcowa konstruktora,
- `driver_pos_before_race`, `constructor_pos_before_race` – pozycja w mistrzostwach przed wyścigiem,
- `hist_track_avg` – historyczna średnia pozycja kierowcy na danym torze.



Rysunek 1: Rozkład klas decyzyjnych oraz rozkład pozycji startowych w zbiorze.

Cechy numeryczne poddano standaryzacji (`StandardScaler`). Zbiór podzielono na część treningową (80%) i testową (20%).

3 Modelowanie i architektura systemu

3.1 Random Forest - model bazowy


=== Random Forest (bazowy) ===

Accuracy: 0.6285

F1 (weighted): 0.6147

CV Accuracy (5): 0.6267

	precision	recall	f1-score	support
Podium	0.56	0.56	0.56	622
Poza punktami	0.69	0.79	0.74	2670
Punkty	0.48	0.35	0.40	1408
accuracy			0.63	4700
macro avg	0.58	0.57	0.57	4700
weighted avg	0.61	0.63	0.61	4700



Rysunek 2: Metryki Random Forest oraz macierz pomyłek.

3.2 Random Forest - Kalibracja GridSearchCV

Najlepsze parametry RF: {'max_depth': 10, 'min_samples_split': 10, 'n_estimators': 300}
Najlepsza CV accuracy: 0.6441


=== Random Forest (po kalibracji) ===

Accuracy: 0.6370

F1 (weighted): 0.6220

CV Accuracy (5): 0.6441

	precision	recall	f1-score	support
Podium	0.56	0.60	0.58	622
Poza punktami	0.70	0.80	0.75	2670
Punkty	0.49	0.34	0.40	1408
accuracy			0.64	4700
macro avg	0.58	0.58	0.58	4700
weighted avg	0.62	0.64	0.62	4700




Rysunek 3: Metryki skalibrowanego Random Forest oraz macierz pomyłek.

3.3 Support Vector Machine - model bazowy

```
=== SVM (bazowy) ===
Accuracy:      0.6360
F1 (weighted): 0.6101
CV Accuracy (5): 0.6447
```

	precision	recall	f1-score	support
Podium	0.58	0.58	0.58	622
Poza punktami	0.68	0.84	0.75	2670
Punkty	0.48	0.28	0.35	1408
accuracy			0.64	4700
macro avg	0.58	0.56	0.56	4700
weighted avg	0.61	0.64	0.61	4700



Rysunek 4: Metryki SVM oraz macierz pomyłek.

3.4 Support Vector Machine - Kalibracja GridSearchCV

Najlepsze parametry SVM: {'C': 1, 'gamma': 'scale', 'kernel': 'rbf'}
Najlepsza CV accuracy: 0.6447


=== SVM (po kalibracji) ===

Accuracy: 0.6360

F1 (weighted): 0.6101

CV Accuracy (5): 0.6447

	precision	recall	f1-score	support
Podium	0.58	0.58	0.58	622
Poza punktami	0.68	0.84	0.75	2670
Punkty	0.48	0.28	0.35	1408
accuracy			0.64	4700
macro avg	0.58	0.56	0.56	4700
weighted avg	0.61	0.64	0.61	4700




Rysunek 5: Metryki skalibrowanego SVM oraz macierz pomyłek.

3.5 K Nearest Neighbors - model bazowy

```
=== KNN (bazowy) ===
Accuracy:      0.6089
F1 (weighted): 0.5960
CV Accuracy (5): 0.6059
```

	precision	recall	f1-score	support
Podium	0.48	0.59	0.53	622
Poza punktami	0.69	0.77	0.73	2670
Punkty	0.46	0.32	0.38	1408
accuracy			0.61	4700
macro avg	0.54	0.56	0.54	4700
weighted avg	0.59	0.61	0.60	4700



Rysunek 6: Metryki KNN oraz macierz pomyłek.

3.6 K Nearest Neighbors - Kalibracja GridSearchCV

```
Najlepsze parametry KNN: {'metric': 'euclidean', 'n_neighbors': 15, 'weights': 'distance'}  
Najlepsza CV accuracy: 0.6294
```


```
=== KNN (po kalibracji) ===
```

```
Accuracy: 0.6213
```

```
F1 (weighted): 0.6079
```

```
CV Accuracy (5): 0.6294
```

	precision	recall	f1-score	support
Podium	0.54	0.56	0.55	622
Poza punktami	0.69	0.78	0.73	2670
Punkty	0.47	0.34	0.39	1408
accuracy			0.62	4700
macro avg	0.57	0.56	0.56	4700
weighted avg	0.60	0.62	0.61	4700



Rysunek 7: Metryki skalibrowanego KNN oraz macierz pomyłek.

3.7 MLP - model bazowy


=== MLP (bazowy) ===

Accuracy: 0.5983

F1 (weighted): 0.5958

CV Accuracy (5): 0.5991

	precision	recall	f1-score	support
Podium	0.52	0.58	0.55	622
Poza punktami	0.70	0.71	0.71	2670
Punkty	0.43	0.39	0.41	1408
accuracy			0.60	4700
macro avg	0.55	0.56	0.55	4700
weighted avg	0.59	0.60	0.60	4700




Rysunek 8: Metryki MLP oraz macierz pomyłek.

3.8 MLP - Kalibracja GridSearchCV

```
Najlepsze parametry MLP: {'activation': 'relu', 'alpha': 0.001, 'hidden_layer_sizes': (64, 32), 'learning_rate_init': 0.001}
Najlepsza CV accuracy: 0.6286
```


```
=== MLP (po kalibracji) ===
Accuracy: 0.6255
F1 (weighted): 0.6107
CV Accuracy (5): 0.6286
```

	precision	recall	f1-score	support
Podium	0.56	0.59	0.57	622
Poza punktami	0.69	0.79	0.74	2670
Punkty	0.47	0.33	0.39	1408
accuracy			0.63	4700
macro avg	0.57	0.57	0.57	4700
weighted avg	0.61	0.63	0.61	4700



Rysunek 9: Metryki skalibrowanego MLP oraz macierz pomyłek.

3.9 Porównanie modeli po kalibracji



Rysunek 10: Porównanie Accuracy i F1 score modeli.

3.10 System ekspercki - VotingClassifier


Zaimplementowany system ekspercki oparty na VotingClassifier wykorzystał soft voting gdzie każdy model wylicza prawdopodobieństwo. Osiągnął ostatecznie ogólną dokładność na poziomie **Accuracy = 64.26%**.

```

=== System Ekspercki (VotingClassifier) ===
Accuracy:      0.6379
F1 (weighted): 0.6167

```

	precision	recall	f1-score	support
Podium	0.57	0.58	0.58	622
Poza punktami	0.69	0.83	0.75	2670
Punkty	0.50	0.31	0.38	1408
accuracy			0.64	4700
macro avg	0.59	0.57	0.57	4700
weighted avg	0.62	0.64	0.62	4700



Rysunek 11: Porównanie Accuracy i F1 score modeli.

3.11 Logika rozmyta - doradca pit-stopów

Wynik z modelu jest przekazywany do systemu wnioskowania rozmytego typu Mamdaniego. Modeluje on strategię pit-stopów na podstawie:


- **Wejścia:** `zuzycie_opon` [0-100%], `przewaga` [-10s do 10s], `numer_okrazenia` oraz `predykcja_ml` (prognoza szans na zajęcie pozycji na podium/w punktach/poza punktami).
- **Wyjście:** `pilnosc_pit` [0-100] – stopień krytyczności zmiany opon.

Baza reguł uwzględnia np. bardzo wysokie zużycie opon przy spadającym tempie natychmiast generuje komunikat **[PIT]**, podczas gdy dobre tempo odracza decyzję do komunikatu **[ROZWAŻ PIT]** lub **[ZOSTAŃ]**.


```
rules = [
# Reguła 1: Opony bardzo zużyte -> pit
ctrl.Rule(zuzycie_opon["wysokie"], pilnosc_pit["wysoka"]),
# Reguła 2: Opony świeże + 1-miejsce -> zostań
ctrl.Rule(zuzycie_opon["niskie"] & przewaga["prowadzenie"], pilnosc_pit["niska"]),
# Reguła 3: Środkowe okrążenia + średnie zużycie -> być może pit
ctrl.Rule( numer_okrazenia["srednie"] & zuzycie_opon["srednie"], pilnosc_pit["srednia"]),
# Reguła 4: Poza punktami + późne okrążenia -> pit
ctrl.Rule( przewaga["strata"] & numer_okrazenia["pozne"], pilnosc_pit["wysoka"]),
# Reguła 5: Wczesne okrążenia -> nie pit
ctrl.Rule( numer_okrazenia["wczesne"], pilnosc_pit["niska"]),
# Reguła 6: Średnie zużycie + strata -> rozważ pit
ctrl.Rule( zuzycie_opon["srednie"] & przewaga["strata"], pilnosc_pit["srednia"]),
# Reguła 7: Prowadzenie + późne okrążenia + średnie zużycie -> być może pit
ctrl.Rule( przewaga["prowadzenie"] & numer_okrazenia["pozne"] & zuzycie_opon["srednie"], pilnosc_pit["srednia"]),

# Reguła 8: Modele przewidują słaby wynik + średnie zużycie -> pit
ctrl.Rule( predykcja_ml["slaby"] & zuzycie_opon["srednie"], pilnosc_pit["wysoka"]),
# Reguła 9: Modele przewidują podium + prowadzenie -> nie pit
ctrl.Rule( predykcja_ml["mocny"] & przewaga["prowadzenie"], pilnosc_pit["niska"]),
# Reguła 10: Modele przewidują podium + średnie zużycie -> być może pit
ctrl.Rule( predykcja_ml["mocny"] & zuzycie_opon["srednie"], pilnosc_pit["niska"]),
# Reguła 11: Modele niepewne (Punkty) + wysokie zużycie -> pit
ctrl.Rule( predykcja_ml["sredni"] & zuzycie_opon["wysokie"], pilnosc_pit["wysoka"]),
# Reguła 12: Modele niepewne (Punkty) + niskie zużycie -> nie pit
ctrl.Rule( predykcja_ml["sredni"] & zuzycie_opon["niskie"], pilnosc_pit["niska"]),
]
```

Rysunek 12: Reguły logiczne.



Rysunek 13: Funkcje przynależności.



Rysunek 14: Wynik systemu, **zużycie opon: 75%, przewaga: 5s, numer okrążenia: 40/70**